


مبانی داده کاوی علیخانی

جزوه دست نویس امیر محمد خالقی فرید



اپراتور ها

Select Attribute

این اپراتور برای فیلتر کردن ستون ها استفاده میشود. از ویژگی های خاص آن این است که از دیتا ستی که به آن داده میشود فقط و فقط ستون هایی که به عنوان ورودی اپراتور تعریف میشوند در خروجی حضور پیدا میکنند (بقیه ستون ها اصلا رد نمیشوند). یعنی فقط هم ورودی اش را رد میکند.

نکته خیلی مهم:

دیتا ستی که به یک اپراتور داده میشود != ورودی اپراتور

(دیتا ستی که به یک اپراتور داده میشود لزوما دیتا ست ورودی آن نیست ، بلکه صرفا به عنوان یک مرجع به آن اپراتور داده میشود تا اپراتور با توجه به بخش **attribute filter type** خود بخشی از آنرا به عنوان ورودی استفاده و با توجه به نوعش با بقیه آن مدارا کند)

Replace Missing Values

این اپراتور خانه های مقدار دار بخش ورودی خود را رد میکند(در خروجی به همان شکلی که بودند میاورد) اما آنهایی که خانه های خالی یا **Missing Value** هستند را با مقدار بخش **default** جایگزین میکند

Filter Examples

این اپراتور کل دیتا ست داده شده به خود را همواره به طور کامل به عنوان ورودی در نظر میگیرد و با توجه به شرط هایی که در **filters** برای آن تعریف میشود فقط ردیف هایی که شروط مورد نظر را دارا هستند را در خروجی میدهد.

Set Role

به ما امکان توصیف یک نقش برای هر یک از ستون های دیتاستی که به آن داده شده میدهد. تا برای مراحل بعدی آن نقش مورد استفاده قرار گیرد. (ما از آن برای تعریف لیبل استفاده کردیم)

درخت تصمیم گیری / Decision Tree

درخت تصمیم‌گیری با نگاه کردن به مقادیر لیبیل (نتیجه)، بررسی می‌کند که کدام ویژگی اگر مبنا و معیار دسته‌بندی قرار گیرد، باعث می‌شود داده‌ها به گروه‌هایی تقسیم شوند که در هر گروه، مقادیر لیبیل تا حد ممکن مشابه و یکنواخت باشند. سپس بر اساس همان ویژگی و مقادیر آن، داده‌ها را دسته‌بندی می‌کند و این فرآیند را به‌صورت تکراری ادامه می‌دهد تا به نتیجه برسد.

درخت تصمیم‌گیری سعی می‌کند با تعیین شروط مبتنی بر ویژگی‌های دیگر، گروه‌بندی‌هایی ارائه بدهد که مقدار لیبیل هاشون تو یه مایس!

مثلاً:

یه جدول داریم سه تا ستون داره:

- سابقه ورزش
- سن
- توانایی ددلیفت 100 کیلو

توانایی ددلیفت 100 کیلو	سن (سال)	- سابقه ورزش (سال)
ندارد	70	0
ندارد	60	5
دارد	50	10
دارد	40	15
دارد	36	20

اگر لیبیل را توانایی ددلیفت 100 کیلو در نظر بگیریم:

بر اساس معیار سابقه ورزش

و بر اساس معیار سن

به شرط و دو شاخه زیر میرسیم:

به شرط و دو شاخه زیر میرسیم:

میرسیم:

اگر سابقه ورزش ≥ 5 توانایی ددلیفت 100 کیلو ندارد

اگر سن < 50 توانایی ددلیفت 100

100

و در غیر اینصورت دارد!

کیلو ندارد و در غیر

اینصورت دارد!

اینصورت دارد!

Information Gain

یه معیار ساده که فقط میاد چک میکنه ببینه مقادیر ویژگی اگر بر اساسش شرط نوشته بشه چقدر یکنواخت میشه مقادیر لیبیل هاشون بر اساس اون شرط. به کلام ساده در این متد اول میاد میزان تصادفی بودن داده ها رو قبل از دسته بندی بر اساس لیبیل توسط درخت تصمیم گیری میبینه اگه گزینه های توی گروه رنج مقدار لیبیلشون نزدیک تر یا دقیقاً یک مقدار شده باشه، IG بالا میره.

Gain_ratio

بجای اینکه فقط یکنواختی رو چک کنه میاد ببینه داده ها شاخشون تکی نباشه (این نباشه که گروه ها هر کدوم تک عضوی باشن و صرفاً بخاطر این یک نواختی و "مشابه بودن مقادیرشون" بالا رفته باشه) و اگر اینطور بود information Gain شون رو کم کنه تا داده های تک شاخه بیوفتن تو اولویت کمتر. (در نتیجه شروط و خصوصیات که خیلی جزئی هستند اینطوری میوفتن آخر تر و در شکل درخت اونایی که تعداد زیر گره های کمتری دارن بیوفتن پایین مثلاً شاخه های تک برگ بیوفتن پایین)

Rule Induction

با استفاده از نتایج Decision Tree دست به تعریف شروط برای گروه بندی های نسبتاً قابل اتکا و صادق درمورد دیتا ست میزنند.

Naïve Bayes

با شمارش تعداد و میزان حضور یک سری ویژگی ها ویژگی محتمل برای تکرار در آینده را میابد.

